

Durchgeführt im Rahmen des

BMBF-Projekt: ELISE

Dokumentation der Projektarbeit

Entwurf eines kompakten mikrocontrollergestützten Systems zur
Emotionserkennung in einer Virtual-Reality-Umgebung

WiSe 2017/2018 und SoSe 2018

Projektbetreuer:

Medizinische Informatik und Mikrosystementwurf

Prof. Dr. rer. nat. Rainer Brück

Dr.-Ing. Armin Grünewald

M.Sc. David Krönert

Forschungsgruppe für Mustererkennung

Prof. Dr.-Ing. Marcin Grzegorzek

M.Sc. Frédéric Li

Projektteilnehmer:

Artur Piet (Sprecher der Projektgruppe)

Jonas Pöhler (Stellv. Sprecher der Projektgruppe)

Arnaud Eric Toham Waffo

Boris Kamdem

Kevin Orth

Meryem Dural

Minas Michail

Inhaltsverzeichnis

Begrifflichkeiten	5
1 Einleitung	6
1.1 Hintergrund und Motivation	6
1.2 ELISE Projektbeschreibung	6
1.3 Gliederung dieser Dokumentation	6
1.4 Anhang	6
2 Organisation	7
3 Grundlagen	8
3.1 Definition von Emotionen	8
3.2 Virtual Reality (VR)	8
3.3 Sensoren und biophysiological Signale zur Emotionserkennung . .	8
3.3.1 Körpertemperatur-Sensor	8
3.3.2 Blood Volume Pulse-Sensor (BVP)	8
3.3.3 Messen der Sauerstoffsättigung (SpO2)	8
3.3.4 Galvanic Skin Response (GSR)	8
3.3.5 Elektroenzephalografie (EEG)	8
3.3.6 Elektrookulografie (EOG)	8
3.3.7 Analog/Digital-Wandler	8
3.4 Kommunikation	8
3.5 Grundlagen der Mustererkennung	8
3.6 Emotion Recognition Chain (ERC)	9
3.6.1 Datenerfassung	10
3.6.2 Vorverarbeitung	10
3.6.3 Segmentation	10
3.6.4 Merkmalsextraktion	11
3.6.5 Klassifikation	11
4 State-of-the-Art Analyse	12
I Erster Prototype	13
<hr/>	
5 Systementwurf und Konzept	13
5.1 Anforderungen	13
5.2 Konzept	13

5.3	Hardwareauswahl	13
5.3.1	Auswahlkriterien	13
5.3.2	Festlegung der genutzten Hardware	13
5.4	Hardwarearchitektur	13
5.4.1	GSR-Sensor	13
5.4.2	Temperatur-Senosr	13
5.4.3	Pulsoximeter	13
5.4.4	EEG	13
5.4.5	EOG	13
5.4.6	Datenübertragung	13
5.5	Programmierung	13
5.6	Aufnahme der übertragenen Daten	13
6	Realisierung	14
7	Emotionsinduktion	15
7.1	Ablauf	15
7.2	Fragebogen	15
7.3	Szenarien	15
7.3.1	Glück	15
7.3.2	Langeweile	15
7.3.3	Frustration	15
8	Messreihe	16
9	Mustererkennung	17
9.1	Merkmalsextraktion für Emotionserkennung	17
9.1.1	Hand-gefertigte Merkmale	17
9.1.2	Codebook Approach	17
10	Ergebnisse	18
10.1	Ergebnisse der hand-gefertigten Merkmale	18
10.2	Ergebnisse des Codebook Approach	18
10.3	Analyse der Ergebnisse	18
11	Zusammenfassung und Ausblick	19
11.1	Zusammenfassung	19
11.2	Fazit	19
11.3	Ausblick	19
	Abbildungsverzeichnis	20

Tabellenverzeichnis	21
Anhang	22

Begrifflichkeiten

Kurze Beschreibung der verwendeten Begriffe/Abkürzungen

1 Einleitung

Minas

- Next Step: Bitte selbst bei github hochladen oder Artur zuschicken

1.1 Hintergrund und Motivation

1.2 ELISE Projektbeschreibung

1.3 Gliederung dieser Dokumentation

1.4 Anhang

2 Organisation

Artur

- Next Step: Gliederung erstellen

3 Grundlagen

Arnaud

3.1 Definition von Emotionen

Arnaud

3.2 Virtual Reality (VR)

Arnaud, Boris

3.3 Sensoren und biophysiological Signale zur Emotionserkennung

Arnaud, Kevin

3.3.1 Körpertemperatur-Sensor

3.3.2 Blood Volume Pulse-Sensor (BVP)

3.3.3 Messen der Sauerstoffsättigung (SpO2)

3.3.4 Galvanic Skin Response (GSR)

3.3.5 Elektroenzephalografie (EEG)

3.3.6 Elektrookulografie (EOG)

3.3.7 Analog/Digital-Wandler

3.4 Kommunikation

Kevin, Jonas

3.5 Grundlagen der Mustererkennung

Artur

Mustererkennung (enlg. "pattern recognition") ist ein Unterthema des maschinellen Lernens. Das Ziel besteht darin, automatisierte Systeme zu entwerfen, die hoch abstrakte Muster in Daten erkennen können. Konkret heißt dies, dass man Maschinen beibringen möchte komplexer Aufgaben zu lösen, welche vom Menschen nahezu mühelos und natürlich erledigt werden können. Typische Beispiele für die zahlreichen Anwendungsbereiche sind die Objekterkennung, Spracherkennung sowie die

Erkennung und Verfolgung in Bildern. Die Emotionserkennung ist ein Anwendungsbereich der Mustererkennung. Die Hauptidee hinter der Lösung eines Mustererkennungs-Problems ist es, dieses als Klassifikationsproblem zu übersetzen, wobei die zu erkennende Mustern die unterschiedliche Klassen bilden. Die vom Mustererkennungs-System eingegebenen Daten werden dann verarbeitet und der “am nächsten liegenden” Klasse zugeordnet. Beispielsweise können bei der Emotionserkennung die Eingangsdaten Bilder oder physiologische Signale sein, die in verschiedene Klassen eingeteilt werden, welche jeweils einer Emotion entsprechen.

Ein wichtiger Teil eines jeden Mustererkennung-Problems ist der Lernansatz, mit welchem die Maschine lernen soll die Muster in den Daten zu erkennen. Traditionell werden zwei Ansätze verwendet:

- Überwachter Lernansatz: Dieser Ansatz kann nur verwendet werden, wenn vor der Verarbeitung der Daten ein Datenbeschriftungsschritt durchgeführt wurde. In diesem Schritt wird jedem Element des Datensatzes ein Etikett (engl. “label”) zugewiesen, das angibt, welcher Klasse der jeweilige Datenpunkt zugeordnet werden kann. Die zusätzlichen Informationen, die die Etiketten liefern, werden als Grundlage verwendet, um sie mit der Vorhersage des Systems zu vergleichen und zu korrigieren, wenn sie nicht gleich sind.
- Unüberwachter Lernansatz: Dieser Ansatz wird verwendet, wenn keine Etiketten für die Daten vorhanden sind. Unüberwachte Lerntechniken zielen darauf ab, der Maschine beizubringen, Muster in den Daten selbst zu finden. Sie werden meist verwendet, um Einblicke in Daten zu erhalten, deren Struktur unbekannt ist.

Überwachtes Lernen liefert aktuell weit bessere Ergebnisse, jedoch ist die Beschriftung mit Etiketten der Daten nicht immer einfach oder teilweise sogar gar nicht möglich (z.B. wenn die Datenmenge sehr groß ist oder wenn Unsicherheit über die Vergabe der Etiketten besteht). Aus diesem Grund wächst das Interesse an unüberwachten Lernansätzen. Diese Ansätze sind jedoch schwierig zu benutzen, da sie eine große Menge an Daten voraussetzen. Kompromisse sind mit semi-überwachten Lernansätzen möglich, bei denen die Daten für einen Teil des Datensatzes (aber nicht für den ganzen Datensatz) mit Etiketten beschriftet und damit bekannt sind. In diesem Fall kann eine Mischung aus überwachten und Unüberwachten Techniken angewendet werden [1].

3.6 Emotion Recognition Chain (ERC)

Artur

Die Emotion Recognition Chain (ERC) besteht aus fünf Hauptschritten: Datenerfassung, Vorverarbeitung, Segmentierung, Merkmalsextraktion und Klassifizierung

(vgl. Abb. 1). In den folgenden Unterkapiteln wird für jeden Schritt eine allgemeine Erklärung gegeben.

Artur: Need to update the erc image




Abbildung 1: Emotion Recognition Chain: Zeitreihen-Datensätze werden von tragbaren Sensoren aufgenommen (Datenerfassung) und vorverarbeitet (Vorverarbeitung). Die Daten werden dann in Segmente unterteilt (Segmentierung), aus denen Merkmale extrahiert werden (Merkmalsextraktion). Mit den gewonnenen Merkmalen wird schließlich ein Klassifikator trainiert und anschließend dessen Ergebnisse bewertet (Klassifikation).

3.6.1 Datenerfassung

Artur: Später mit dem Rest der Dokumentation abstimmen.

Dieser Schritt der ERC beinhaltet die Auswahl sowie den Aufbau der Sensoren, die Messreihendurchführung um Daten zu erhalten und Etikett-Beschriftungstechniken. All diese Details sind wichtig für die Emotionserkennung, damit relevante und möglichst fehlerfreie Daten von Versuchspersonen für die verschiedenen emotionalen Zustände gewonnen werden können. Dies ist besonders wichtig, da der Datenerfassungsschritt der erste in der ERC ist und die Ergebnisse aller folgenden Schritte direkt von der Qualität des Datensatzes abhängen.

3.6.2 Vorverarbeitung

Normalisierungstechniken wurden auf dem gesamten Datensatz angewendet. Wir haben insbesondere die Standardnormalisierung verwendet, welche den Mittelwert der Daten auf Null setzt und die Einheitsvarianz ergibt [2]. Die Formel für die Standardnormierung lautet:

$$x' = \frac{x - \bar{x}}{\sigma} \quad (1)$$

wobei x ein Datenpunkt eines Sensorkanales, \bar{x} ist der Durchschnitt der Gesamtheit für diesen Sensorkanal und σ ist die entsprechende Standardabweichung.

3.6.3 Segmentation

Ziel dieses Schrittes ist es, Teile von Daten zu identifizieren, welche wichtige Informationen über die zu erkennenden Emotionen enthalten. Dies geschieht durch Filtern der Daten und Ausschließen von Segmenten, die für das Klassifizierungsproblem nicht relevant sind. Zusätzlich wird die zu verarbeitende Datenmenge reduziert,

indem Segmente eines Zeitfensters fester Größe aus den Daten extrahiert werden. Diese Vorgehensweise ist heute in der Praxis besonders wichtig, da sonst hardwarebedingte Einschränkungen die zu verarbeitende Datenmenge begrenzen können.

In dieser Projektarbeit wurde ein Schiebefensteransatz (engl. “sliding window approach”) verwendet. Ziel der Methode ist die Segmentierung der vorhandenen Daten in kleinere Einheiten, um die Merkmalsextraktion sowie die anschließende Klassifizierung zu vereinfachen oder gar erst zu ermöglichen. Die Länge des Zeitfensters (engl. “time window”) und des Gleitschritts (engl. “sliding stride”) sind zu bestimmende Parameter (und werden auch als “Hyperparameter” bezeichnet), wobei sich das Zeitfenster auf die feste Größe pro extrahiertem Segment und der Gleitschritt auf die Lücke zwischen dem Beginn jedes Zeitfensters bezieht. Es ist zu beachten, dass sich aufeinanderfolgende Zeitfenster überlappen können, sobald der definierte Schritt kleiner als das Zeitfenster ist.

Die Daten werden auf Zeitstempel-Ebene mit Etiketten beschriftet, basierend auf den von der jeweiligen Versuchsperson ausgefüllten Fragebögen. Jedem Zeitfenster wird ein Etikett zugeordnet, welches das dominante (d.h. am meisten vorhandene) Etikett der im Fenster enthaltenen Zeitstempel basiert. Es wird davon ausgegangen, dass jedes Zeitfenster nur von einer Emotion belegt ist.

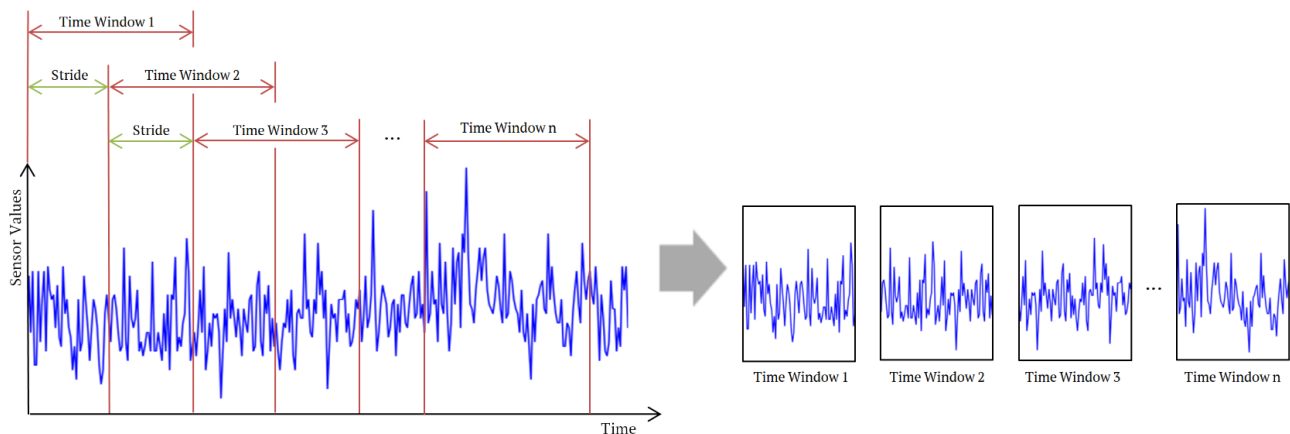


Abbildung 2: Schiebefenster-Segmentierung: Die Daten werden durch ein Fenster fester Größe in kleinere Segmente aufgeteilt. Das Fenster wird mit einem festen Gleichschritt geschoben, um den aufeinanderfolgend Daten-Zeitfenster zu erhalten.

3.6.4 Merkmalsextraktion

3.6.5 Klassifikation

4 State-of-the-Art Analyse

Jonas

- Next Step: Gliederung erstellen

5 Systementwurf und Konzept

Kevin, Jonas

5.1 Anforderungen

5.2 Konzept

5.3 Hardwareauswahl

5.3.1 Auswahlkriterien

5.3.2 Festlegung der genutzten Hardware

5.4 Hardwarearchitektur

5.4.1 GSR-Sensor

5.4.2 Temperatur-Senosr

5.4.3 Pulsoximeter

5.4.4 EEG

5.4.5 EOG

5.4.6 Datenübertragung

5.5 Programmierung

5.6 Aufnahme der übertragenen Daten

6 Realisierung

Jonas, Kevin

- Next Step: Gliederung erstellen

7 Emotionsinduktion

Minas

7.1 Ablauf

Minas

7.2 Fragebogen

Boris

7.3 Szenarien

Meryem

7.3.1 Glück

Minas

7.3.2 Langeweile

Boris

7.3.3 Frustration

Meryem

8 Messreihe

Kevin, Artur

9 Mustererkennung

Artur

9.1 Merkmalsextraktion für Emotionserkennung

9.1.1 Hand-gefertigte Merkmale

9.1.2 Codebook Approach

10 Ergebnisse

Artur

10.1 Ergebnisse der hand-gefertigten Merkmale

10.2 Ergebnisse des Codebook Approach

10.3 Analyse der Ergebnisse

11 Zusammenfassung und Ausblick

Noch nicht zugeordnet

11.1 Zusammenfassung

11.2 Fazit

11.3 Ausblick

Abbildungsverzeichnis

1	Emotion Recognition Chain: Zeitreihen-Datensätze werden von tragbaren Sensoren aufgenommen (Datenerfassung) und vorverarbeitet (Vorverarbeitung). Die Daten werden dann in Segmente unterteilt (Segmentierung), aus denen Merkmale extrahiert werden (Merkmalsextraktion). Mit den gewonnenen Merkmalen wird schließlich ein Klassifikator trainiert und anschließend dessen Ergebnisse bewertet (Klassifikation).	10
2	Schiebefenster-Segmentierung: Die Daten werden durch ein Fenster fester Größe in kleinere Segmente aufgeteilt. Das Fenster wird mit einem festen Gleichschritt geschoben, um den aufeinanderfolgend Daten-Zeitfenster zu erhalten.	11

Tabellenverzeichnis

Anhang

References

- [1] X. Zhu. Semi-supervised learning literature survey, July 2008.
- [2] J. Grus. *Data Science from Scratch*. O'Reilly Media, April 2015.